UNIVERSIDAD NACIONAL DE TIERRA DEL FUEGO

Laboratorio de Datos I

Programa de la asignatura

Asignatura optativa transversal · 60 horas · 9 unidades · Régimen cuatrimestral

Asignatura	Laboratorio de Datos I
Carácter	Optativa, transversal a diversas carreras de grado
Carreras destinatarias	Ingenierías, ciencias económicas, ciencias sociales, ciencias ambientales y naturales, sistemas y educación
Régimen de cursado	Cuatrimestral
Carga horaria total	**60 horas**, organizadas en **9 unidades**
Carga horaria semanal	**4 horas** teórico-prácticas, durante 15 semanas
Modalidad	Bimodal: 36 h presenciales (60 %) y 24 h virtuales sincrónicas (40 %), con aula virtual de soporte permanente
Evaluación	**2 exámenes parciales domiciliarios** y **1 Trabajo Integrador**
Régimen de aprobación	Regularización con los parciales aprobados y aprobación por examen final realizando presentación del proyecto integrador
Año académico	2026
Equipo docente	Flavio A. Gragnolati

1 Fundamentación

1.1 Encuadre general y sentido de la asignatura

La creciente disponibilidad de datos en todos los ámbitos de la vida social, económica, productiva y ambiental plantea la necesidad de formar profesionales capaces de comprender, analizar y utilizar información de manera rigurosa para la toma de decisiones. La ciencia de datos integra conceptos y herramientas provenientes de la estadística, la programación, el análisis exploratorio, el aprendizaje automático y la visualización, y permite abordar problemáticas complejas en contextos muy diversos: industria, gestión pública, salud, educación, ambiente y ciencias sociales, entre otros.

Por su carácter **optativo y transversal**, esta asignatura no se fundamenta en el perfil de una única carrera, sino en una competencia que atraviesa los perfiles de egreso de todas las carreras a las que se ofrece: la capacidad de **fundamentar decisiones profesionales en evidencia empírica cuantitativa**, produciéndola, evaluándola críticamente y comunicándola con honestidad. Esa competencia ya no puede considerarse patrimonio exclusivo de las disciplinas cuantitativas: la digitalización de los registros administrativos, productivos, ambientales y de gestión ha vuelto disponible para todas las profesiones un volumen de datos que excede con holgura las herramientas de análisis que cada plan de estudios provee por separado.

El propósito de “Laboratorio de Datos I” es, entonces, ofrecer un **núcleo instrumental común**: un recorrido completo por el ciclo de vida de un proyecto de datos que cada estudiante especializa luego en los problemas de su propio campo. La asignatura enseña a formular una pregunta que los datos puedan contestar, a obtener y preparar la evidencia, a construir y evaluar modelos, y a comunicar el resultado, incluida su incertidumbre, a quien deba decidir con él. En el contexto regional, esto adquiere un anclaje concreto: la gestión pública provincial, el monitoreo ambiental y glaciológico, la actividad turística y antártica, la pesca y la industria fueguina generan hoy conjuntos de datos que constituyen material de trabajo genuino y no meramente ilustrativo.

La asignatura adopta como entorno de trabajo **Python y herramientas de código abierto** (notebooks y bibliotecas estándar), por su disponibilidad sin costo de licencia, su adopción profesional extendida y su capacidad para sostener un trabajo **reproducible y trazable**. Incorpora asimismo criterios de **ética, responsabilidad y buenas prácticas** en el manejo de datos, no como un apartado final, sino como una dimensión que se retoma en cada unidad.

1.2 Aporte al perfil de egreso

La asignatura contribuye al perfil de egreso de las carreras destinatarias en tres planos:

- **Cognitivo:** comprender el ciclo de vida de un proyecto de datos, los supuestos que subyacen a cada técnica y los límites de lo que un conjunto de datos puede sostener.
- **Procedimental:** operar con solvencia un entorno de análisis reproducible; explorar, preparar, modelar, evaluar y visualizar datos reales.
- **Actitudinal:** asumir una posición crítica y éticamente responsable frente a los datos, los modelos y las decisiones automatizadas que de ellos se derivan.

1.3 Articulación vertical

La asignatura se ubica en el **ciclo superior** de los planes de estudio y opera como nexo entre la formación básica y las instancias de integración final.

Hacia atrás, se apoya en los espacios de formación básica que las carreras ya proveen: matemática de los primeros años (vectores, matrices, funciones y su representación gráfica), probabilidad y estadística descriptiva (medidas de posición y dispersión, nociones de variable aleatoria) y una introducción a la programación imperativa (variables, estructuras de control, funciones, listas). La asignatura **no reenseña** esos contenidos: los pone en uso. Para las carreras cuyos planes no incluyen un espacio de programación, el **Taller de Programación** del Programa "Laboratorio de Datos" cumple la función de nivelación previa.

Hacia adelante, la asignatura habilita y alimenta:

- **"Laboratorio de Datos II"**, espacio avanzado previsto en el mismo programa institucional, del cual constituye el requisito natural.
- Las **asignaturas de modelado propias de cada carrera** —econometría, investigación operativa, estadística aplicada, análisis de datos ambientales, métodos cuantitativos, minería de datos—, a las que aporta la infraestructura computacional y el criterio de validación que esas materias suelen dar por supuestos.
- El **trabajo final, la tesina, la práctica profesional supervisada o el seminario de investigación**, instancias en las que la o el estudiante debe formular un problema, obtener datos, analizarlos y comunicar resultados de manera autónoma. Es allí donde el rendimiento de esta asignatura se vuelve más visible.
- La participación en **laboratorios, proyectos interdisciplinarios y competencias de ciencia de datos**.

Ubicación recomendada: a partir del tercer año, una vez aprobados los espacios de matemática, estadística y programación, y con anterioridad al inicio del trabajo final de carrera.

1.4 Articulación horizontal

La articulación horizontal opera en dos sentidos simultáneos.

Dentro de cada carrera, la asignatura **complementa sin superponerse** a los espacios del mismo nivel. No sustituye a Estadística (no desarrolla inferencia, contraste de hipótesis ni diseño experimental con la profundidad que esa asignatura requiere) ni a Programación (no aborda estructuras de datos, complejidad algorítmica ni ingeniería de software). Su objeto propio es precisamente la **articulación de ambas**: el análisis de datos computacionalmente implementado, con su método, sus criterios de validación y sus modos de comunicación. Delimitar así el alcance evita duplicaciones curriculares y permite que la optativa se ofrezca a carreras con formaciones cuantitativas muy dispares.

Entre carreras, la asignatura es en sí misma un dispositivo de articulación horizontal del plan de estudios de la Universidad. Al cursar en una misma comisión estudiantes de ingeniería, economía, ciencias sociales y ciencias ambientales, el aula se convierte en un espacio de **trabajo interdisciplinario efectivo**: los conjuntos de datos provienen de dominios diversos, los grupos de trabajo se conforman deliberadamente de manera mixta y el **Trabajo Integrador** ancla la asignatura en un problema de la carrera de origen de cada estudiante. La transversalidad no es, por lo tanto, un atributo administrativo del espacio curricular, sino un recurso didáctico deliberado.

En el plano institucional, la asignatura articula además con las restantes iniciativas del Programa "Laboratorio de Datos": el Taller de Programación (nivelación), las capacitaciones docentes y los futuros espacios avanzados.

1.5 Requisitos de cursado

Los siguientes requisitos son **recomendados y no excluyentes**:

- **Programación básica:** nociones de Python o de un lenguaje imperativo similar (variables, tipos de datos simples, estructuras de control, funciones, manejo elemental de listas o arreglos).
- **Matemática de los primeros años:** operaciones elementales con vectores y matrices, resolución de ecuaciones simples, comprensión de funciones y gráficas (rectas, polinomios, exponenciales y logarítmicas).
- **Probabilidad y estadística básica:** nociones elementales de probabilidad y variable aleatoria; familiaridad, al menos intuitiva, con media, mediana, varianza y desvío estándar.
- **Lógica y pensamiento computacional:** compuertas lógicas, tablas de verdad y capacidad de descomponer un problema en pasos.
- **Manejo de herramientas informáticas:** uso básico de computadora, conectividad y disposición para trabajar en entornos como Google Colab, Jupyter Notebook o IDEs equivalentes, y en el aula virtual institucional.

*La puesta a punto del entorno de trabajo (cuenta, notebooks, primeras celdas de código) se resuelve mediante una **guía de autoaprendizaje asincrónica previa al inicio del cursado** ("semana 0"), de modo de no consumir horas de clase en tareas de configuración.*

2 Objetivos

2.1 Hilos conductores

Los siguientes interrogantes atraviesan la asignatura de principio a fin. No se responden en una clase ni se agotan en una unidad: se retoman, se complejizan y se resignifican en cada una, y constituyen el criterio último para evaluar la comprensión alcanzada.

1. ¿Qué preguntas puede responder un conjunto de datos y cuáles no? ¿Cómo se traduce un problema real de una disciplina en una pregunta que los datos estén en condiciones de contestar?
2. ¿Qué decisiones, y qué supuestos implícitos, se toman al limpiar, transformar y representar los datos, y de qué modo condicionan lo que después se podrá concluir?
3. ¿Cómo distinguimos una señal genuina de un artefacto producido por el azar, el sesgo del muestreo, el sobreajuste o la fuga de información?
4. ¿Qué significa que un modelo "funcione bien"? ¿Bien según qué métrica, para quién y a costa de qué errores?
5. ¿Cómo se comunica un resultado incierto a quien debe tomar una decisión a partir de él?
6. ¿Quién gana y quién pierde cuando una decisión se delega en un sistema construido a partir de datos?

Correspondencia entre los hilos conductores y las unidades de contenido

Hilo conductor	Unidades
1. Qué puede y qué no puede responder un conjunto de datos	1 · 2 · 9
2. Decisiones y supuestos en la preparación de los datos	2 · 6
3. Señal frente a artefacto: azar, sesgo, sobreajuste y fuga de información	2 · 3 · 4 · 5
4. Qué significa que un modelo funcione bien: métricas, contexto y costos del error	3 · 4 · 5
5. Comunicación de resultados inciertos a quien decide	8 · 9
6. Quién gana y quién pierde con las decisiones automatizadas	1 · 4 · 6 · 8

2.2 Objetivos generales

Se espera que, al finalizar la asignatura, las y los estudiantes:

- **Comprendan y recorran de manera autónoma el ciclo de vida completo de un proyecto de datos**, de la formulación del problema a la comunicación de los resultados, aplicándolo con rigor metodológico a problemas propios de su campo disciplinar.
- **Dominen instrumentalmente un entorno de trabajo abierto y reproducible en Python**, empleándolo con criterio para explorar, modelar y visualizar datos, y no como un repertorio de recetas cuya aplicación no se justifica.
- **Asuman una actitud crítica y éticamente responsable** frente a los datos, los modelos y las decisiones que de ellos se derivan, reconociendo en cada caso sus alcances, sus supuestos y sus límites.

2.3 Objetivos específicos

Al finalizar la asignatura, se espera que las y los estudiantes sean capaces de:

1. **Formular** un problema de su disciplina como un problema de datos, identificando el tipo de tarea que corresponde (regresión, clasificación, agrupamiento o análisis exploratorio) y la evidencia necesaria para abordarlo. *(Unidad 1)*
2. **Realizar un análisis exploratorio de datos (EDA)** completo: caracterizar los tipos de variables, detectar y tratar datos faltantes y valores atípicos, y describir la distribución de los datos con las medidas y los gráficos apropiados. *(Unidad 2)*
3. **Preparar los datos para el modelado**, aplicando transformaciones, escalado, codificación de variables categóricas y construcción de variables derivadas, y **justificando cada decisión** tomada. *(Unidades 2 y 6)*
4. **Construir, ajustar e interpretar modelos supervisados de regresión** (lineal, polinómica y regularizada), evaluando su desempeño con métricas adecuadas (MAE, MSE, RMSE, R^2) e interpretando sus coeficientes y sus limitaciones. *(Unidad 3)*
5. **Construir, ajustar e interpretar modelos supervisados de clasificación** (regresión logística, KNN, árboles de decisión, ensambles), **seleccionando y justificando** las métricas apropiadas al contexto del problema, en particular ante clases desbalanceadas. *(Unidad 4)*
6. **Diseñar esquemas válidos de validación** (train/test, validación cruzada), reconociendo y previniendo el sobreajuste y la fuga de información (*data leakage*). *(Unidades 3 y 4)*

7. **Aplicar técnicas no supervisadas** (k-means, clustering jerárquico, PCA) para explorar la estructura de un conjunto de datos, reducir su dimensionalidad e interpretar los grupos y las componentes obtenidas. *(Unidad 5)*
8. **Obtener datos de fuentes externas** mediante APIs y *scraping* básico, evaluando las condiciones legales y éticas de su uso. *(Unidad 6)*
9. **Representar y analizar datos de texto** (tokenización, matriz documento-término, TF-IDF), aplicar un modelo clásico de procesamiento de lenguaje natural y explicar conceptualmente su diferencia con los enfoques basados en *embeddings* y modelos de lenguaje. *(Unidad 7)*
10. **Producir visualizaciones eficaces y comunicar hallazgos —y su incertidumbre—** a audiencias técnicas y no técnicas, en formato de informe escrito y de presentación oral. *(Unidad 8)*
11. **Desarrollar de manera autónoma un proyecto integrador** de pequeña escala sobre un problema vinculado a su carrera, trabajando de modo reproducible y trazable en notebooks e integrando todas las capacidades anteriores. *(Unidad 9)*

3 Condiciones de regularidad y aprobación de la asignatura

Las condiciones de regularidad y aprobación se rigen por el **Reglamento General de Estudios de Pregrado y Grado, Resolución (R.O.) N.º 350/2014** y sus modificatorias. La escala de calificación es de 1 (uno) a 10 (diez): se **aprueba** con 4 (cuatro) puntos, equivalentes al dominio de al menos el 60 % de los contenidos y competencias evaluados.

La asignatura se regulariza mediante la aprobación **de dos exámenes parciales domiciliarios** y la implementación de, al menos, **el 80 % del Trabajo Integrador** al finalizar la cursada. El cumplimiento de estos requisitos habilita al estudiante a presentarse a la instancia de examen final, que consiste en la exposición y defensa del Trabajo Integrador completo. La aprobación definitiva de la asignatura se obtiene una vez superada dicha instancia final.

3.1 Instancias de evaluación

Instancia	Descripción	Cant.	Peso
Exámenes parciales domiciliarios	Resolución individual de un **caso o escenario con datos reales**, sobre el que se deben aplicar los conceptos de las unidades evaluadas. Se resuelven fuera del horario de clase, con un plazo acotado, y se entregan en el aula virtual como **notebook comentado más informe breve**. Carácter teórico-práctico: se evalúan tanto la implementación como la justificación de las decisiones metodológicas y la interpretación de los resultados. Cada parcial cuenta con una instancia de recuperación.	2	60 % (30 % c/u)

Instancia	Descripción	Cant.	Peso
Trabajo Integrador	Proyecto aplicado, individual o en grupos reducidos, sobre un problema vinculado a la carrera de origen o a un interés propio. Comprende tres componentes: informe escrito breve, notebook comentado y reproducible y defensa oral (en examen final). El informe incorpora dos anexos de documentación, de una página como máximo cada uno: ficha de datos y ficha de modelo/sistema —o ficha de análisis/sistema cuando no corresponde un modelo predictivo—.	1	40 %
Total			**100 %**

3.2 Condiciones de regularidad (cursada aprobada)

Para regularizar la asignatura se requiere el cumplimiento **concomitante** de:

a) Acreditar el **75 % de asistencia** a los encuentros, presenciales y virtuales sincrónicos. La totalidad de los encuentros reviste carácter teórico-práctico.
b) **Aprobar los dos exámenes parciales domiciliarios**, o sus respectivas instancias de recuperación, con 4 (cuatro) puntos o más en cada uno.

La regularización de la cursada **requiere la aprobación de ambos exámenes parciales** domiciliarios **y la implementación de, al menos, el 80 % del Trabajo Integrador al finalizar el período de cursada**.

El **examen final consiste en la presentación, exposición y defensa del Trabajo Integrador completo**. La aprobación de esta instancia determina la aprobación definitiva de la asignatura.

3.3 Aprobación en condición de estudiante libre

Dado el carácter de laboratorio de la asignatura, la aprobación en condición de **estudiante libre** requiere acreditar las mismas capacidades prácticas que se desarrollan durante la cursada. Comprende tres instancias:

a) **Trabajo previo.** Presentar, con una antelación mínima de 30 (treinta) días corridos a la fecha de la mesa de examen, un Trabajo Integrador equivalente al exigido durante la cursada (informe escrito y notebook reproducible), sobre una consigna y un conjunto de datos acordados previamente con la cátedra. Su aprobación es condición para acceder a las instancias siguientes.
b) **Instancia práctica presencial, de carácter eliminatorio.** Resolución completa de un caso de análisis de datos en notebook, con dataset provisto y tiempo acotado.
c) **Instancia oral teórica.** Sobre la totalidad de los contenidos del programa, incluyendo la defensa del trabajo presentado.

Se requiere una calificación de 4 (cuatro) puntos o más en cada instancia.

3.4 Correlatividades

En su condición de asignatura optativa transversal, “Laboratorio de Datos I” no establece correlatividades propias de aprobación; los requisitos enunciados en el punto 1.5 son recomendados y no excluyentes. Cuando el plan de estudios de la carrera de origen fije correlatividades para los espacios optativos, regirá lo dispuesto por los **artículos 28 y 30 de la Resolución (R.O.) N.º 350/2014**: para acceder a la aprobación o a la promoción de la asignatura deberá contarse con la aprobación del examen final de la o las asignaturas correlativas; en caso contrario, sólo podrá regularizarse la cursada.

4 Contenidos de la asignatura

Los contenidos conservan la organización en **nueve unidades** del programa de la asignatura, con la carga horaria redistribuida sobre un total de **60 horas**. Se presenta primero una tabla resumen y a continuación el desarrollo analítico de cada unidad.

4.1 Tabla resumen

Unidad	Horas	%	Semanas	Modal.
Unidad 1. Introducción, ciclo de vida de proyectos de datos y aspectos éticos	**4**	7 %	1	P
Unidad 2. Análisis exploratorio de datos (EDA), estadística descriptiva y visualización exploratoria básica	**8**	13 %	2 – 3	P / V
Unidad 3. Modelos de regresión y fundamentos de aprendizaje supervisado	**10**	17 %	4 – 6	P / V
Unidad 4. Clasificación: modelos, métricas y datos desbalanceados	**10**	17 %	6 – 8	P / V
Unidad 5. Modelos no supervisados: clustering y reducción de la dimensionalidad	**8**	13 %	9 – 10	P / V
Unidad 6. Obtención de datos y datos no numéricos	**8**	13 %	11 – 12	P / V
Unidad 7. Introducción al procesamiento de lenguaje natural (NLP)	**6**	10 %	13 – 14	P / V
Unidad 8. Visualización de datos y comunicación de resultados	**4**	7 %	14 – 15	P / V
Unidad 9. Proyecto integrador	**2**	3 %	15	P
Total	**60**	**100 %**	**15**	—

*Modalidad: **P** = encuentro presencial · **V** = encuentro virtual sincrónico (véase el punto 5). El desarrollo del Trabajo Integrador (Unidad 9) se realiza fuera del horario de clase; el seguimiento tutorial se canaliza por el encuentro virtual de la semana 12 y por el aula virtual.*

4.2 Desarrollo analítico

4.2.1 Introducción, ciclo de vida de proyectos de datos y aspectos éticos — 4 h

¿Qué es la ciencia de datos? Rol en distintas disciplinas y ámbitos: industria, gestión pública, salud, ambiente, ciencias sociales.

Ciclo de vida de un proyecto de datos. Formulación del problema → obtención de datos → limpieza y preparación → modelado → evaluación → comunicación.

Documentación mínima del conjunto de datos: motivación, procedencia, composición, período, permisos, transformaciones, usos previstos y límites. La ficha de datos hace visible esta evidencia sin reemplazar el notebook ni las fuentes.

Tipos de problemas. Regresión, clasificación, *clustering*, recomendación y análisis exploratorio.

Consideraciones prácticas y éticas. Sesgos en datos y modelos. Privacidad y protección de datos. Impacto de las decisiones automatizadas y responsabilidad profesional.

Herramientas de la materia. Python y notebooks (Google Colab u otra alternativa). Introducción a NumPy, pandas y bibliotecas de visualización.

La puesta a punto del entorno se resuelve mediante la guía asincrónica de la "semana 0". El tratamiento de los aspectos éticos se inicia aquí pero ***no se agota en esta unidad****: se retoma en la Unidad 4 (sesgo, elección de métricas y costos del error), en la Unidad 6 (privacidad y condiciones de uso de APIs y scraping) y en la Unidad 8 (comunicación responsable de la incertidumbre).*

4.2.2 Análisis exploratorio de datos (EDA), estadística descriptiva y visualización exploratoria básica — 8 h

Tipos de datos en ciencia de datos. Numéricos, categóricos, ordinales, fechas y texto.

Preparación de datos numéricos. Detección y tratamiento de datos faltantes. Detección y tratamiento de *outliers*. Estandarización y normalización.

Estadística descriptiva. Medidas de tendencia central (media, mediana, moda). Medidas de dispersión (rango, varianza, desvío estándar, error estándar). Distribuciones frecuentes y rudimentos de probabilidad.

Visualización exploratoria básica. Histogramas, *scatter plots*, gráficos de barras, *boxplots*, *violin plots*, gráficos de torta y sus limitaciones.

Introducción a la ingeniería de características. Transformaciones (logarítmica, escalado, combinaciones simples). Variables derivadas (razones, diferencias). Variables de fecha y tiempo (día de la semana, mes, estacionalidad simple).

Los rudimentos de probabilidad y las medidas descriptivas integran los requisitos previos de la asignatura y se abordan de manera compacta. La práctica guiada se concentra en recorrer ***el flujo completo de EDA sobre un caso****; la ejercitación de refuerzo se resuelve de manera autónoma con guías del aula virtual.*

4.2.3 Modelos de regresión y fundamentos de aprendizaje supervisado — 10 h

Formulación de problemas de regresión.

Regresión lineal. Modelo e interpretación de coeficientes. Método de mínimos cuadrados. Implementación con scikit-learn.

Regresión polinómica. Aumento de flexibilidad y riesgo de *overfitting*. Visualización del ajuste y del error.

Fundamentos de *machine learning*. Función de costo. Idea de optimización y gradiente descendente (a nivel conceptual).

Regularización. Ideas de Ridge y Lasso. *Trade-off* sesgo–varianza.

Curvas de aprendizaje como diagnóstico introductorio de sesgo, varianza y necesidad de datos: lectura de la brecha entre entrenamiento y validación y de su tendencia al aumentar el tamaño de muestra.

Métricas para regresión. MAE, MSE, RMSE y R^2: qué mide cada una y cuándo corresponde utilizarlas.

4.2.4 Clasificación: modelos, métricas y datos desbalanceados — 10 h

Formulación de problemas de clasificación.

Regresión logística. Interpretación como clasificador binario. Frontera de decisión.

División de datos. *Train/test split*. Validación cruzada (*cross-validation*). *Data leakage*: ejemplos y prevención.

Evaluación bajo condiciones realistas: cambio de distribución entre desarrollo y uso, y evaluación por período o grupo relevante cuando el promedio pueda ocultar fallos.

Diferencia entre discriminación, calibración y regla de decisión. Lectura básica de diagramas de confiabilidad; la calibración avanzada y la corrección automática de cambios de distribución quedan fuera del núcleo.

Clasificadores básicos. Clasificadores lineales. K-Nearest Neighbors (KNN). Árboles de decisión. Ensambles: *Random Forest* (concepto e implementación básica). Opcionalmente, según disponibilidad de tiempo, introducción a SVM y *kernels*.

Métricas para clasificación. Matriz de confusión. *Accuracy*, *precision*, *recall* y *F1-score*. ROC–AUC y curvas *precision–recall*.

Clases desbalanceadas. Reponderación de clases. *Oversampling* y *undersampling* (a nivel conceptual).

4.2.5 Modelos no supervisados: clustering y reducción de la dimensionalidad — 8 h

Motivación del aprendizaje no supervisado. Qué se busca cuando no hay variable objetivo.

Reducción de dimensionalidad. Idea de componentes principales. PCA: varianza explicada e interpretación. Uso de PCA para visualización y preprocesado.

Clustering. k-means: concepto, inicialización y elección del número de *clusters*. Clustering jerárquico: idea general y ejemplo práctico.

Aplicaciones. Exploración de estructuras en datos. Detección de grupos y de observaciones atípicas (*outliers*).

4.2.6 Obtención de datos y datos no numéricos — 8 h

Adquisición de datos desde APIs. Obtención de *keys*, uso de *requests*. Ejemplos de APIs públicas.

Scraping básico de páginas web. Estructura HTML. Extracción simple de datos. Consideraciones legales y éticas.

Trabajo con datos categóricos y mixtos. Codificación de variables categóricas (*one-hot*, ordinal).

Introducción a otros tipos de datos. Datos de texto: estructura documental básica. Ejemplos breves de datos geoespaciales y series de tiempo, a nivel ilustrativo.

4.2.7 Introducción al procesamiento de lenguaje natural (NLP) — 6 h

Preprocesamiento de texto. Tokenización, *stopwords*, lematización y *stemming* (conceptual).

Representación de texto. Matriz documento–término. Frecuencia y TF-IDF. Nubes de palabras y visualización simple.

Modelos clásicos de NLP. Clasificación de documentos (por ejemplo, KNN o Naive Bayes sobre TF-IDF). Detección de tópicos: idea de LSA, NMF y LDA, con un ejemplo sencillo.

Introducción a *embeddings* y modelos modernos. Idea de vectores densos de palabras y documentos. Diferencia conceptual con bolsa de palabras y TF-IDF. Mención de los modelos de lenguaje grandes (LLM), sus posibles usos y sus limitaciones.

4.2.8 Visualización de datos y comunicación de resultados — 4 h

Principios de diseño para la visualización de datos. Percepción visual: forma, tamaño, color y posición. Buenas y malas prácticas (ejemplos comparativos).

Elección de gráficos según el objetivo. Comparación, distribución, relación, composición y evolución temporal.

Storytelling con datos. Estructuración de una historia basada en datos. Adaptación del mensaje a audiencias técnicas y no técnicas. Comunicación de la incertidumbre.

Documentación y reproducibilidad. Uso de notebooks como medio de comunicación (texto, código y gráficos). Principios básicos de trazabilidad y organización del análisis.

Herramientas de visualización. Profundización en bibliotecas (matplotlib, seaborn, plotly u otras que se definan). Mención de *dashboards* y reportes interactivos (visión general).

*La unidad no introduce la visualización, sino que la **sistematiza**: se viene practicando de manera transversal desde la Unidad 2 (exploratoria), la Unidad 3 (diagnóstico del ajuste y del error), la Unidad 4 (curvas ROC y precision–recall) y la Unidad 5 (proyección en componentes principales). Las 4 horas permiten cubrir los cinco bloques en clase, apoyando la profundización en bibliotecas con práctica autónoma guiada desde el aula virtual. La unidad se evalúa en el Parcial 2 —cuyo informe y notebook exigen precisamente comunicar resultados— y en el Trabajo Integrador.*

4.2.9 Proyecto integrador — 2 h

Carga horaria destinada a las **presentaciones finales y a la discusión colectiva**. El desarrollo del proyecto se realiza por fuera del horario de clase, y el seguimiento tutorial se canaliza a través del encuentro virtual de la semana 12 y del aula virtual, de manera continua a lo largo de la segunda mitad del cuatrimestre.

Planteo y desarrollo de un proyecto aplicado, individual o en pequeños grupos, vinculado a problemáticas de las carreras de origen o a intereses específicos de las y los estudiantes.

Etapas mínimas:

- Formulación del problema y definición del tipo de tarea (regresión, clasificación o análisis exploratorio / no supervisado).
- EDA, limpieza y preparación de datos.
- Ficha de datos, de una página como máximo, sustentada por el notebook y la fuente.
- Implementación de uno o más modelos, reglas, indicadores o procedimientos analíticos adecuados a la pregunta.

- Evaluación con métricas apropiadas y discusión de las limitaciones.
- Estrategia de evaluación que imite el uso futuro mediante una partición temporal, por grupo o por entidad cuando corresponda; resultados desagregados cuando el promedio pueda ocultar fallos.
- Ficha de modelo/sistema —o ficha de análisis/sistema—, de una página como máximo, con línea base, datos de evaluación, métricas, condiciones de uso, revisión humana, límites y cambios que invalidarían la conclusión.
- Visualización y comunicación de resultados: informe breve, notebook comentado y presentación.

En las 2 horas de clase: consultas y discusión colectiva.

5 Metodología de enseñanza

La asignatura se dicta en **modalidad bimodal**: encuentros presenciales de laboratorio, encuentros virtuales sincrónicos y un aula virtual de soporte permanente. La proporción se define a partir de un criterio simple: **el trabajo en máquina con acompañamiento docente directo es el núcleo de la materia y se sostiene presencialmente**; los contenidos de carácter más expositivo, las consignas y consultas de los parciales domiciliarios y el seguimiento tutorial del Trabajo Integrador se resuelven eficazmente en formato virtual.

5.1 Componentes de la modalidad

Componente	Carga	Descripción
Presencial	36 h (60 %)	Nueve encuentros de 4 h en laboratorio de informática o con dispositivos personales (formato “notebook en mano”). Exposición conceptual breve y práctica guiada y autónoma en máquina, con acompañamiento docente directo.
Virtual sincrónico	24 h (40 %)	Seis encuentros de 4 h por videoconferencia. Se destinan a contenidos de carácter más expositivo o conceptual, a la presentación de las consignas de los parciales domiciliarios y a la consulta y el seguimiento tutorial del Trabajo Integrador.
Virtual asincrónico (aula virtual)	Soporte permanente	No computa como horas de dictado. Aloja los notebooks y las guías de cada unidad, videos breves, ejercitación autónoma no calificada, foros de consulta, el repositorio de conjuntos de datos de la cátedra y la entrega de todas las instancias evaluativas.

5.2 Estrategias de enseñanza

- **Clases teórico-prácticas.** La totalidad de los encuentros integra exposición conceptual y trabajo en máquina; no hay clases exclusivamente teóricas. Distribución estimada del tiempo de clase: aproximadamente un tercio de exposición y discusión, dos tercios de práctica guiada y resolución autónoma en notebook.
- **Aprendizaje basado en problemas.** Se trabaja con ejemplos y casos tomados de las distintas disciplinas presentes en la Universidad, con conjuntos de datos reales o realistas, incluyendo datos de origen regional.
- **Aula invertida en las unidades de mayor componente conceptual.** Lectura o video breve en el aula virtual antes del encuentro, de modo que el tiempo sincrónico se destine a la práctica y a la discusión.

- **Uso intensivo de notebooks** como entorno de experimentación, de documentación y de evaluación: todas las instancias evaluativas se resuelven y se entregan en ese formato.
- **Trabajo interdisciplinario.** Los grupos se conforman deliberadamente de manera mixta, aprovechando la heterogeneidad de las carreras de origen como recurso didáctico.
- **Evaluación de proceso, no de memoria.** Los parciales domiciliarios plantean un caso con datos y un plazo, y exigen recorrer el análisis completo y comunicarlo. La ejercitación semanal del aula virtual, no calificada, funciona como preparación y devolución formativa.
- **Semana 0.** Guía de autoaprendizaje asincrónica, previa al inicio del cursado, para la puesta a punto del entorno de trabajo (cuenta de Colab, primeros notebooks, verificación de bibliotecas).
- **Trabajo autónomo estimado.** Entre 2 y 3 horas semanales de ejercitación, además del desarrollo del Trabajo Integrador durante la segunda mitad del cuatrimestre.

5.3 Recursos

- Python y notebooks (Google Colab o equivalente); NumPy, pandas, matplotlib/seaborn y scikit-learn.
- Aula virtual institucional: materiales, guías, foros, entregas y devoluciones.
- Plataforma de videoconferencia para los encuentros virtuales sincrónicos.
- Repositorio de conjuntos de datos de la cátedra, con casos de origen regional y multidisciplinar.
- **Ruta complementaria no evaluable · Uso crítico, responsable y eficiente de chatbots y modelos de lenguaje.** La guía transversal aborda modelo mental, contexto, herramientas, workflows, RAG, agentes, multimodalidad, alucinación, privacidad, verificación e integridad académica. En Laboratorio de Datos I se evalúa el uso responsable y la capacidad de auditar salidas; no la construcción de agentes, el fine-tuning ni sistemas RAG de producción. Abrir la guía transversal

6 Cronograma tentativo

Quince semanas de 4 horas semanales, con un total de **60 horas de dictado**. La distribución comprende **36 horas presenciales (60 %)** y **24 horas virtuales sincrónicas (40 %)**, equivalentes a nueve encuentros presenciales y seis encuentros virtuales. La guía asincrónica de la semana 0 no se computa dentro de la carga horaria. Se mantiene la organización general de contenidos prevista en el programa vigente.

Sem.	Unidad	Contenidos	Mod.	Evaluación / hitos
0	—	Guía de autoaprendizaje: entorno de trabajo, Colab, primeras celdas de código	V-A	No presencial · no computa
1	U1 (4 h)	Ciencia de datos y ciclo de vida. Tipos de problemas. Ética y responsabilidad. Herramientas	P	
2	U2 (4 h)	Tipos de datos. Preparación: faltantes, outliers, estandarización. Estadística descriptiva	P	
3	U2 (4 h)	Visualización exploratoria básica. Introducción a la ingeniería de características	V	**Actividad** práctica guiada en notebook.
4	U3 (4 h)	Regresión lineal. Mínimos cuadrados. Interpretación de coeficientes	P	

Sem.	Unidad	Contenidos	Mod.	Evaluación / hitos
5	U3 (4 h)	Regresión polinómica. Overfitting. Función de costo y gradiente descendente	V	**Actividad** de aplicación y análisis del ajuste.
6	U3 (2 h) + U4 (2 h)	Regularización (Ridge, Lasso). Métricas de regresión · Clasificación: regresión logística	P	
7	U4 (4 h)	Train/test, validación cruzada, data leakage. KNN, árboles, Random Forest	P	
8	U4 (4 h)	Métricas de clasificación. Clases desbalanceadas. Consigna y consultas del Parcial 1	V	**Consigna Parcial 1** (U1–U4)
9	U5 (4 h)	Reducción de dimensionalidad. PCA: varianza explicada e interpretación	P	
10	U5 (4 h)	Clustering: k-means y jerárquico. Aplicaciones	P	**Entrega Parcial 1** · Propuesta del Trabajo Integrador
11	U6 (4 h)	APIs y requests. Scraping básico. Consideraciones legales y éticas	P	
12	U6 (4 h)	Codificación de categóricas. Otros tipos de datos: texto, geoespacial, series de tiempo	V	Tutoría del Trabajo Integrador
13	U7 (4 h)	Preprocesamiento de texto. TF-IDF. Clasificación de documentos. Tópicos	P	
14	U7 (2 h) + U8 (2 h)	Embeddings y LLM · Principios de diseño para la visualización y elección de gráficos	V	**Consigna Parcial 2** (U5–U8)
15	U8 (2 h) + U9 (2 h)	Storytelling, herramientas de visualización y reproducibilidad · Presentaciones del Trabajo Integrador	V	Entrega del Parcial 2 — último día de clases. Acreditación del avance mínimo requerido del Trabajo Integrador. Presentación de los requisitos para su entrega y defensa en el examen final.

Referencias de modalidad: *P = presencial · V = virtual sincrónico · V-A = virtual asincrónico.*

La distribución de las clases computables comprende **nueve encuentros presenciales, equivalentes a 36 horas**, y **seis encuentros virtuales sincrónicos, equivalentes a 24 horas**.

Cada examen parcial contará con una instancia de recuperación, ubicada dentro del período previsto por el Calendario Académico. El **Parcial 2 deberá entregarse el último día de clases**, sin establecerse un plazo posterior al cierre del cursado.

El Trabajo Integrador se desarrollará durante la segunda mitad del cuatrimestre con instancias de orientación y seguimiento. Su presentación y defensa no se realizarán durante las clases: constituirán la **consigna central del examen final de la asignatura**. Al finalizar la cursada, deberá acreditarse el grado de avance requerido para obtener la regularidad.

7 Bibliografía

7.1 Bibliografía básica

- McKinney, W. (2022). *Python for Data Analysis* (3.ª ed.). O'Reilly.

- Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow* (3.ª ed.). O'Reilly.
- James, G., Witten, D., Hastie, T., Tibshirani, R. y Taylor, J. (2023). *An Introduction to Statistical Learning with Applications in Python*. Springer. Se incorpora a Jonathan Taylor, coautor de la edición con aplicaciones en Python.
- Provost, F. y Fawcett, T. (2013). *Data Science for Business*. O'Reilly.
- VanderPlas, J. (2016). *Python Data Science Handbook*. O'Reilly.
- INRIA y comunidad de scikit-learn. (s. f.). *Machine Learning in Python with scikit-learn*. Curso abierto con contenidos, ejercicios y laboratorios sobre preparación de datos, pipelines, validación, modelos supervisados y aprendizaje no supervisado.

7.2 Bibliografía complementaria

- Gebru, T., Morgenstern, J., Vecchione, B., Wortman Vaughan, J., Wallach, H., Daumé III, H., & Crawford, K. (2021). Datasheets for datasets. Communications of the ACM, 64(12), 86–92. https://doi.org/10.1145/3458723
- Mitchell, M., Wu, S., Zaldivar, A., Barnes, P., Vasserman, L., Hutchinson, B., Spitzer, E., Raji, I. D., & Gebru, T. (2019). Model cards for model reporting. Proceedings of the Conference on Fairness, Accountability, and Transparency, 220–229. https://doi.org/10.1145/3287560.3287596
- Moreno-Torres, J. G., Raeder, T., Alaiz-Rodríguez, R., Chawla, N. V., & Herrera, F. (2012). A unifying view on dataset shift in classification. Pattern Recognition, 45(1), 521–530. https://doi.org/10.1016/j.patcog.2011.06.019
- Knaflic, C. N. (2015). Storytelling with Data. Wiley. Lectura de referencia para visualización, comunicación de resultados y adaptación del mensaje a diferentes audiencias, especialmente en la Unidad 8.
- Cairo, A. (2016). The Truthful Art: Data, Charts, and Maps for Communication. New Riders. Lectura de referencia para diseño, análisis crítico y uso responsable de visualizaciones en la Unidad 8.
- Jurafsky, D. y Martin, J. H. (s. f.). Speech and Language Processing (3.ª ed., borrador de acceso abierto). Lectura de referencia para procesamiento de lenguaje natural, representación de texto, clasificación, tópicos, embeddings y modelos de lenguaje en la Unidad 7.
- Han, J., Kamber, M. y Pei, J. (2011). Data Mining: Concepts and Techniques (3.ª ed.). Morgan Kaufmann.
- Bishop, C. M. (2006). Pattern Recognition and Machine Learning. Springer.
- Murphy, K. P. (2012). Machine Learning: A Probabilistic Perspective. MIT Press.
- Murphy, K. P. (2022). Probabilistic Machine Learning: An Introduction. MIT Press. Referencia actualizada para fundamentos probabilísticos, regresión, clasificación, modelos latentes y aprendizaje no supervisado.
- Deisenroth, M. P., Faisal, A. A. y Ong, C. S. (2020). Mathematics for Machine Learning. Cambridge University Press. Material de consulta para mínimos cuadrados, optimización, gradientes, regularización y análisis de componentes principales.
- Kuhn, M. y Silge, J. (2022). Tidy Modeling with R. O'Reilly. Referencia metodológica sobre workflows de modelado, preprocesamiento, remuestreo, ajuste de hiperparámetros, evaluación y prevención de fuga de información, con independencia del lenguaje utilizado en la materia.

- Molnar, C. (s. f.). Interpretable Machine Learning: A Guide for Making Black Box Models Explainable (2.ª ed., libro abierto en línea). Referencia para interpretación de modelos, importancia de variables, explicaciones globales y locales, limitaciones de los métodos explicativos y comunicación responsable de resultados.
- Wickham, H. y Grolemund, G. (2017). R for Data Science. O'Reilly. Referencia metodológica para la organización del análisis, la transformación de datos, la visualización y la comunicación reproducible, con independencia del lenguaje de programación.

7.3 Recursos abiertos, cursos y plataformas de consulta

Los siguientes recursos se utilizarán de manera seleccionada como apoyo conceptual, fuente de ejemplos, material de laboratorio, banco de datos o referencia para el Trabajo Integrador. Su inclusión no implica la utilización completa de sus cursos, repositorios o colecciones de notebooks.

- Google Machine Learning Crash Course, de Google. Recurso introductorio para regresión, clasificación, funciones de pérdida, gradiente, generalización y variables categóricas.
- MLU-Explain, de Amazon Machine Learning University. Ensayos visuales e interactivos sobre modelos, métricas, equidad, explicabilidad y fundamentos de aprendizaje automático.
- Galería oficial de ejemplos de scikit-learn. Banco de ejemplos sobre preprocesamiento, métricas, regresión, clasificación, ensambles, clustering, reducción de dimensionalidad y análisis de texto.
- mlcourse.ai, de la comunidad OpenDataScience. Curso abierto utilizado como fuente de ejercicios y actividades de ampliación sobre EDA, validación, modelos clásicos y ensambles.
- Machine Learning Zoomcamp, de DataTalks.Club. Referencia para la estructuración de proyectos aplicados, evaluación de modelos y organización de entregables reproducibles.
- Made With ML, de Goku Mohandas. Guía aplicada sobre formulación de problemas, ciclo de vida de proyectos, preparación de datos, evaluación, testing, reproducibilidad e iteración de sistemas de aprendizaje automático.
- Stanford CS229: Machine Learning, de Stanford University. Notas y materiales de profundización para la preparación docente y la consulta de fundamentos matemáticos.
- DrivenData. Plataforma de competencias y casos con datos vinculados con salud, ambiente, educación, desarrollo y gestión pública, utilizable como fuente de problemas para actividades y proyectos.
- OpenML. Plataforma de conjuntos de datos, tareas y benchmarks reproducibles para prácticas comparativas entre modelos y grupos de estudiantes.
- Applied ML, de Eugene Yan. Colección de casos y artículos técnicos sobre decisiones de modelado, métricas, restricciones operativas y sistemas de aprendizaje automático reales.
- Hugging Face LLM Course. Recurso de ampliación para tokenización moderna, transformers, modelos preentrenados, embeddings y modelos de lenguaje.

- Dive into Deep Learning, de Aston Zhang, Zachary C. Lipton, Mu Li y Alexander J. Smola. Libro interactivo de profundización sobre redes neuronales, embeddings, atención y procesamiento moderno del lenguaje.
- Practical Deep Learning for Coders, de fast.ai. Recurso optativo para estudiantes que desarrollen proyectos específicos basados en aprendizaje profundo.
- Documentación oficial actualizada de Python, NumPy, pandas, Matplotlib, seaborn, Plotly, scikit-learn y de las restantes bibliotecas utilizadas durante la asignatura.